

ЛАБОРАТОРНА РОБОТА 1.3

ПЕРВИННИЙ СТАТИСТИЧНИЙ АНАЛІЗ ТА ПЕРЕВІРКА РЕЗУЛЬТАТІВ ВИМІРЮВАНЬ ПРОГРАМНОГО ЗАБЕЗПЕЧЕННЯ

Мета – навчитися будувати закони розподілів метрик, визначати відхилення від оптимальних значень та їх причини.

Теоретичні відомості

Статистичний аналіз, який виконується з метою визначення залежностей між метриками, складається з трьох етапів: первинний статистичний аналіз, кореляційний аналіз та регресійний аналіз

Метою первинного статистичного аналізу являється визначення закону розподілу випадкової величини, точніше визначення відповіді на питання: чи є даний закон розподілу випадкової величини нормальним? В ході дослідження спочатку будується графічний вигляд (гістограма) закону розподілу.

Для побудови гістограми проводиться розбиття варіаційного ряду на класи. Для цього фіксується рівномірне розбиття осі спостережень Δ_h на класи, де h — крок розбиття. Крок розбиття визначається із співвідношення:

$$h = \frac{b - a}{m},$$

де a — початок спостережень (окремий випадок $x_1 = a$); b — кінець спостережень (окремий випадок $x_r = b$); m — кількість елементів розбиття Δ_h (кількість класів).

Кількість класів — величина довільна, проте варто вибирати m непарним і таким, щоб гістограма, по можливості, не мала осциляції випадковостей і була більш-менш «гладкою» [8]. Існує оптимальна кількість класів, яка залежить від обсягу даних вибірки n та від типу їх закону розподілу. При $n < 100$ можна використати формулу

$$m = \begin{cases} \left[\sqrt{n} \right], & \text{коли } \left[\sqrt{n} \right] - \text{парне,} \\ \left[\sqrt{n} \right] - 1, & \text{коли } \left[\sqrt{n} \right] - \text{непарне,} \end{cases}$$

де $[]$ — ціла частина.

Після побудови гістограми за її виглядом можна відсіяти частину метрик, які мають багатомодальний вигляд, так як статистичний аналіз залежностей побудований на дослідженні унімодальних законів розподілу. Для уточнення законів розподілу визначаються статистичні характеристики, такі як середнє квадратичне відхилення:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n-1} \sum_{i=1}^r (x_i - \bar{x})^2 n_i = \sum_{i=1}^n (x_i - \bar{x})^2 f_i, \sigma = S.$$

Математичне сподівання:

$$\bar{x} = \hat{v}_1 = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n} \sum_{i=1}^r x_i n_i = \sum_{i=1}^r x_i f_i.$$

На основі значень математичного сподівання проводиться видалення аномальних явищ (відхилень), при якому за допомогою квантилів розподілу Стюдента визначаються «грубі» значення, тобто такі значення, які не потрапляють під заданий закон розподілу, і значно віддалені від математичного сподівання.

Обчислені значення статистики

$$t = \frac{|x_{\text{гр}} - \bar{x}|}{S}$$

порівнюють з критичним значенням $t_{\alpha/2, \nu}$ (квантиль розподілу Стюдента). При

$$t \geq t_{\alpha/2, \nu},$$

$x_{\text{гр}}$ підлягає видаленню, де $t_{\alpha/2, \nu}$ – квантиль t -розподілу Стюдента. Замість $t_{\alpha/2, \nu}$ можна використати квантиль $u_{\alpha/2}$ нормального розподілу. Прийняти: довірча ймовірність – $\gamma = 0.95$ та ймовірність «промаху» поза довірчого інтервалу $\alpha = 1 - \gamma = 1 - 0.95 = 0.05$. З таблиці розподілів t -Стюдента прийняти: $t_{\alpha/2, \nu} = 1.96$. Це значення використовувати в подальших розрахунках для $t_{\alpha/2, \nu}$ та $u_{\alpha/2}$.

Після видалення аномального значення необхідно виконати заново обчислення статистичних характеристик та провести переформування варіаційного ряду. Проте така процедура не є ітераційною.

Після видалення аномальних явищ проводяться обчислення коефіцієнтів асиметрії та ексцесу. Коефіцієнт асиметрії:

$$\hat{A} = \frac{\hat{\mu}_3}{\hat{\sigma}^3} = \frac{1}{n\hat{\sigma}^3} \sum_{i=1}^n (x_i - \bar{x})^3 = \frac{1}{n\hat{\sigma}^3} \sum_{i=1}^r (x_i - \bar{x})^3 n_i = \frac{1}{\hat{\sigma}^3} \sum_{i=1}^n (x_i - \bar{x})^2 f_i.$$

Коефіцієнт ексцесу:

$$\hat{E} = \frac{\hat{\mu}_4}{\hat{\sigma}^4} = \frac{1}{n\hat{\sigma}^4} \sum_{i=1}^n (x_i - \bar{x})^4 = \frac{1}{n\hat{\sigma}^4} \sum_{i=1}^r (x_i - \bar{x})^4 n_i = \frac{1}{\hat{\sigma}^4} \sum_{i=1}^n (x_i - \bar{x})^4 f_i.$$

Для всіх метрик, які пройшли попередній етап проводиться порівняння коефіцієнтів асиметрії та ексцесу із заданим теоретично нормальним. Для нормального розподілу коефіцієнти ексцесу та асиметрії приймають значення 0. Після цього на основі гістограм та висновків аналізу числових характеристик робиться висновок про «нормальність» закону розподілу величини.

Кінцевою метою первинного статистичного аналізу є визначення, чи належить побудований закон до нормального. Причиною цього є те, що подальший аналіз базується на перевірці на «нормальність» закону розподілу, тобто кожний з наступних етапів починається цією перевіркою, і в залежності від відповіді застосовуються різні методи обчислень.

Завдання

1. Побудувати гістограми прямих та непрямих метрик згідно із варіантом.

2. Розрахувати статистичні характеристики (математичне сподівання, середнє квадратичне відхилення, коефіцієнт асиметрії, коефіцієнт ексцесу).

3. Провести інтервальне оцінювання параметрів (визначити верхню та нижню межі).

4. Визначити можливі відхилення.

5. Визначити закон розподілу.

Методичні рекомендації

Побудувати гістограми для 5-и прямих та 3-х непрямих метрик за варіантом (додаток 2, таблиця 1). Для побудови гістограми використати виміряні вами проекти (не менше 20). Ще дві непрямі метрики підібрати самостійно. Вибрати їх таким чином, щоб вони залежали від однієї чи декількох прямих метрик (на основі теоретичних знань).

Розрахувати математичне сподівання, дисперсію, середнє квадратичне відхилення, коефіцієнти асиметрії та ексцесу для кожної метрики. Визначити та вилучити аномальні значення. Пояснити відхилення. Ідентифікувати закон розподілу кожної метрики.

Всі розрахунки проводити у MS Excel або математичних чи статистичних середовищах (Matlab, Statistica, Stat і т.д.). Файл з розрахунками додати до звіту.

Контрольні запитання

1. Що включає в себе первинний статистичний аналіз?
2. Як побудувати гістограму?
3. Що таке гістограма?
4. Як перевірити точність отриманих даних?
5. Які статистичні характеристики використовуються для визначення відхилень?
6. Що таке математичне сподівання?
7. Що таке дисперсія?
8. Що таке середнє квадратичне відхилення?
9. Для чого використовується коефіцієнт асиметрії?
10. Що значить коефіцієнт ексцесу?
11. Як визначити, чи існує нормальний закон розподілу?
12. Що таке закон розподілу?
13. Які види гістограм ви знаєте?

ЛІТЕРАТУРА: [1, 4-8].

ДОДАТКИ

Додаток 1. Основні об'єктно-орієнтовані метрики та засоби їх вимірювання

Таблиця 1

№	Позначення	Відмірювана сутність	Назва	Опис
1	AMW	Клас	Середня вага метода (Average Method Weight)	Середня статична складність усіх методів у класі. Цикломатичне число МакКейба, яке використовується для визначення складності метода
2	ATFD	Клас/Метод	Доступ до зовнішніх даних (Access To Foreign Data)	Число атрибутів від непов'язаних класів, що звернена безпосередньо або які викликаються за допомогою методів доступу
3	BOvR	Клас	Перевизначення співвідношення базового класу (Base Class Overriding Ratio)	Число методів у виміряному класі, який перевизначає методи від базового класу, поділені на загальне число методів в класі.
4	CC	Метод	Змінюванні класи (Changing classes)	Число класів, в яких визначаються методи, викликанні виміряними методами
5	CDISP	Операція	Дисперсія зчеплення (Coupling Dispersion)	Число класів, в яких операції викликанні вимірюваними операціями від , поділено на CINT
6	CINT	Метод	Щільність зчеплення (Coupling Intensity)	Число роздільних операцій викликаних виміряними операціями
7	CM	Метод	Змінні методи (Changing methods)	Число роздільних методів викликаних виміряними методами
8	CYCLO	Операція	Цикломатичне число МакКейба (McCabe's Cyclomatic Number)	Число лінійно-незалежних шляхів через операцію

№	Позначення	Відмірювана сутність	Назва	Опис
9	FDP	Метод	Зовнішні постачальники даних (Foreign Data Providers)	Число класів, у яких визначаються атрибути доступу у відповідності з метрикою ATFD.
10	HIT	Клас	Висота дерева наслідування (Height of Inheritance Tree)	Максимальна довжина шляху від класу до його найглибшого підкласу
11	WOC	клас	Вага класу (weight of the class)	Кількість функціональних відкритих методів класу (тобто не таких, що встановлюють або читають дані) поділено на загальну кількість відкритих методів
12	WMC	клас	Зважена кількість класів (weighted method count)	Сума статичної складності усіх методів класів.
13	TCC	клас	Щільність зчеплення класів (Tight Class Cohesion)	Відносна кількість пар методів класу, що отримують спільний доступ хоча б до одного атрибуту вимірюваного класу
14	PNAS	клас	Відсоток доданих нових сервісів (Percentage of newly added services)	Кількість відкритих методів класу, що не перевантажені або спеціалізовані відносно попередників, поділено на загальну кількість відкритих методів
15	NProtM	клас	Кількість захищених методів (Number of Protected Members)	Кількість захищених методів та атрибутів класу.
16	NOPA	клас	Кількість відкритих атрибутів (Number of Public Attributes)	Кількість відкритих атрибутів класу.

№	Позначення	Відмірювана сутність	Назва	Опис
17	NOM	клас	Кількість методів (Number of Methods)	Кількість методів класу
18	NOAV	метод	Кількість використаних змінних (Number of Accessed Variables)	Загальне число змінних до яких отримав доступ вимірюваний метод. Змінні включають параметри, локальні змінні, а також екземплярні та глобальні змінні
19	NOAM	клас	Кількість методів аксесорів (Number of Accessor Methods)	Кількість методів аксесорів, що встановлюють та зчитують дані
20	MAXNESTING	метод	Максимальний рівень вкладеності (Maximum Nesting Level)	Максимальний рівень вкладеності структур управління в методі
21	LOC	метод	Кількість рядків коду (Lines of Code)	Кількість рядків коду методу включаючи пусті рядки та коментарі
22	LAA	метод	Локальність доступу до атрибутів (Locality of Attribute Accesses)	Кількість атрибутів з класу, в якому визначений метод, поділено на загальну кількість змінних, до яких отримано доступ методом. Включаючи атрибути, до яких доступ отримано через аксесори

Таблиця 2
Інструменти вимірювання метрик

№	інструмент	№	інструмент
1	Visual Studio, Resource Standard Metrics, Ваш вибір	6	SourceMonitor, EZ – Metrix, Ваш вибір
2	Ndepend, EZ – Metrix, Ваш вибір	7	Visual Studio, Resource Standard Metrics, Ваш вибір
3	SourceMonitor, Resource Standard Metrics, Ваш вибір	8	Ndepend, SourceMonitor, Ваш вибір
4	Visual Studio, EZ – Metrix, Ваш вибір	9	SourceMonitor, Resource Standard Metrics, Ваш вибір
5	Ndepend, Resource Standard Metrics, Ваш вибір	10	Resource Standard Metrics, EZ – Metrix, Ваш вибір

Примітка: «Ваш вибір» - це вузько направлений вимірювач мови програмування ВСІХ ваших 20-ти проектів (наприклад, Jhawk для Java чи CPPDepend для C). Якщо ваші проекти на різних мовах, то вибирайте той, якого не висвітлено у теоретичних відомостях до даної роботи.

Додаток 2. Варіанти завдань до лабораторних робіт 1.2 (п.6 завдань), 1.3 та 2.1.

Таблиця 1

Варіант	Прямі метрики*	Непрямі метрики*
1	CYCLO, NOM, NOC, CALL, FOUT	AMW, ATFD, BOvM
2	LOC, NOM, NOP, NDD, HIT	CC, CDISP, CINT
3	CYCLO, LOC, NOC, FOUT, NDD	CM, WOC, FDP
4	NOM, NOC, NOP, NDD, CALL	WMC, TCC, PNAS
5	NOP, LOC, HIT, NOM, CALL	NProtM, NOPA, NOAV
6	CYCLO, NOP, HIT, FOUT, NOC	NOAM, MAXNESTING, LAA
7	LOC, NOC, NDD, CALL, NOM	AMW, ATFD, BOvM
8	CYCLO, NOM, NOC, CALL, FOUT	CC, CDISP, CINT
9	LOC, NOM, NOP, NDD, HIT	CM, WOC, FDP
10	CYCLO, LOC, NOC, FOUT, NDD	WMC, TCC, PNAS
11	NOM, NOC, NOP, NDD, CALL	NProtM, NOPA, NOAV
12	NOP, LOC, HIT, NOM, CALL	NOAM, MAXNESTING, LAA
13	CYCLO, NOP, HIT, FOUT, NOC	AMW, ATFD, BOvM
14	LOC, NOC, NDD, CALL, NOM	WMC, TCC, PNAS
15	CYCLO, NOM, NOC, CALL, FOUT	NProtM, NOPA, NOAV

*якщо вимірювач не підтримує одну з вказаних метрик, то замінюємо її іншою, проте чітко відслідковуючи її належність до понять «пряма»/ «непряма».